

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN 1



TÌM HIỂU BÀI TOÁN TEXT-TO-MUSIC GENERATION

Giảng viên	: Nguyễn Xuân Đức
Doãn Đăng Khoa	: B22DCKH068
Nguyễn Minh Sáng	: B22DCKH102
Lớp	: D22CQKH02-B

Hà Nội, 05/ 2026

Mục lục

1. Tổng quan bài toán Text-to-Music Generation.....	1
1.1 Định nghĩa bài toán.....	1
1.2 Thách thức kỹ thuật.....	1
1.3 Hướng tiếp cận chung.....	1
2. Các giai đoạn phát triển (Evolution).....	2
2.1 Giai đoạn 1: Biểu diễn ký hiệu (Symbolic Representations).....	2
2.2 Giai đoạn 2: Biểu diễn phổ âm (Spectrogram).....	2
2.3 Giai đoạn 3: Nén tín hiệu học sâu (End-to-End Deep Audio Compression).....	2
2.4 Giai đoạn 4: Khuếch tán tiềm ẩn & Điều kiện hóa đa phương thức (Hiện hành).....	2
3. Các mô hình Text-to-Music phổ biến hiện nay.....	3
3.1 MusicGen (2023).....	3
3.2 Stable Audio Open (2024).....	3
3.3 LeVo (2025).....	3
3.4 ACE-Step (2025/2026).....	3
3.5 AudioX (2026).....	4
3.6 Stable Audio 3.0 (2026).....	4
4. Prompt Engineering trong Text-to-Music Generation.....	6
4.1 Cấu trúc cơ bản của Prompt.....	6
4.2 Kỹ thuật Tạo sinh Tăng cường Truy xuất (RAG).....	6
5. Dataset cho Text-to-Music Generation.....	7
5.1 MusicCaps.....	7
5.2 MTG-Jamendo.....	7
5.3 IF-caps.....	7
6. Đánh giá chất lượng Text-to-Music.....	8
6.1 Các chỉ số khách quan (Objective Metrics).....	8
6.2 Các chỉ số chủ quan (Subjective Metrics).....	8
7. Research gaps và Thách thức hiện tại.....	9
7.1 Khả năng điều khiển đa phương thức chi tiết:.....	9
7.2 Sự thiếu hụt dữ liệu văn hóa địa phương:.....	9
7.3 Chi phí tính toán và Kiến trúc:.....	9
8. Hướng triển khai đồ án.....	10
9. Tài liệu tham khảo.....	11

1. Tổng quan bài toán Text-to-Music Generation

1.1 Định nghĩa bài toán

Text-to-Music Generation thuộc lĩnh vực Trí tuệ Nhân tạo Tạo sinh (Generative AI) và Xử lý Tín hiệu Âm thanh. Mục tiêu của bài toán là xây dựng mô hình máy học có khả năng chuyển đổi văn bản mô tả (text prompt) thành tín hiệu âm thanh kỹ thuật số (audio waveform) biểu diễn âm nhạc, đáp ứng các yêu cầu về thể loại, nhạc cụ và nhịp điệu [1]. Quá trình này yêu cầu ánh xạ giữa không gian dữ liệu rời rạc của ngôn ngữ và không gian liên tục của tín hiệu sóng âm [2].

1.2 Thách thức kỹ thuật

- **Mật độ dữ liệu cao:** Âm thanh tiêu chuẩn chất lượng cao được lấy mẫu ở tần số 44.1 kHz hoặc 48 kHz. Việc xử lý trực tiếp yêu cầu hệ thống dự đoán hàng chục triệu điểm dữ liệu, vượt quá giới hạn bộ nhớ của các kiến trúc học sâu thông thường [3].
- **Cấu trúc phân cấp:** Âm nhạc đòi hỏi sự gắn kết giữa cao độ, trường độ, nhịp điệu, âm sắc và cường độ. Việc căn chỉnh chính xác mô tả văn bản ngắn với chuỗi âm thanh phức tạp đòi hỏi khả năng xử lý ngữ cảnh cao [2].

1.3 Hướng tiếp cận chung

Thay vì mô hình hóa trực tiếp trên cấp độ điểm lấy mẫu thô, các hệ thống Text-to-Music hiện đại sử dụng thuật toán nén âm thanh học sâu để thu gọn tín hiệu thành các biểu diễn tiềm ẩn (latent representations) hoặc token rời rạc. Điều này cho phép áp dụng mô hình ngôn ngữ tự hồi quy hoặc mô hình khuếch tán để sinh nhạc [1].

2. Các giai đoạn phát triển (Evolution)

Quá trình phát triển các phương pháp sinh âm nhạc AI trải qua 4 giai đoạn chính [1] :

2.1 Giai đoạn 1: Biểu diễn ký hiệu (Symbolic Representations)

- *Phương pháp*: Sinh phổ nhạc kỹ thuật số (MIDI, MusicXML) bằng các mô hình NLP.
- *Hạn chế*: Âm thanh máy móc, thiếu âm sắc nhạc cụ vật lý và không tái tạo được giọng hát.

2.2 Giai đoạn 2: Biểu diễn phổ âm (Spectrogram)

- *Phương pháp*: Chuyển sóng âm thành Phổ Mel 2D và áp dụng các mô hình thị giác máy tính để sinh ảnh phổ.
- *Hạn chế*: Phổ Mel bỏ qua thông tin pha (phase). Việc tái tạo sóng âm qua thuật toán xấp xỉ gây nhiễu và làm giảm chất lượng âm thanh [4].

2.3 Giai đoạn 3: Nén tín hiệu học sâu (End-to-End Deep Audio Compression)

- *Phương pháp*: Sử dụng bộ mã hóa nén sóng âm thành token rồi raster thông qua Lượng tử hóa Vector Phần dư (RVQ) [3].
- *Đặc điểm*: Các Mô hình Ngôn ngữ Lớn (LLM) dự đoán chuỗi token này, cho phép sinh âm thanh trực tiếp mà không cần qua phổ Mel.

2.4 Giai đoạn 4: Khuếch tán tiềm ẩn & Điều kiện hóa đa phương thức (Hiện hành)

- *Phương pháp*: Khử nhiễu tín hiệu trong không gian tiềm ẩn kết hợp với cơ chế điều kiện linh hoạt (văn bản, video, âm thanh). Các kiến trúc mới nhất cho phép sinh các đoạn nhạc dài (từ 4 đến 6 phút) với tốc độ cao và hỗ trợ tinh chỉnh cục bộ [5].

3. Các mô hình Text-to-Music phổ biến hiện nay

Bối cảnh nghiên cứu AI sinh âm nhạc trong giai đoạn 2023-2026 đã chuyển dịch mạnh mẽ sang các kiến trúc kết hợp, khả năng sinh nhạc dài hạn (long-form) và điều khiển đa phương thức.

3.1 MusicGen (2023)

- **Ý tưởng chính:** Mô hình ngôn ngữ đơn giai đoạn dự đoán song song các luồng token âm học [3].
- **Kiến trúc:** EnCodec (RVQ) kết hợp Transformer tự hồi quy. Sử dụng cơ chế "Mô hình độ trễ xen kẽ" (Delay Interleaving Pattern) để xử lý song song nhiều codebook [3].
- **Ưu điểm:** Tốc độ suy luận cao; kiến trúc đơn giản, cung cấp mã nguồn mở.
- **Hạn chế:** Bị giới hạn bộ nhớ ngữ cảnh đối với các cấu trúc lặp lại dài hạn.

3.2 Stable Audio Open (2024)

- **Ý tưởng chính:** Nâng cấp khuếch tán tiềm ẩn bằng kiến trúc DiT thay cho U-Net truyền thống [7].
- **Kiến trúc:** Waveform Autoencoder + T5-base (xử lý văn bản) + Diffusion Transformer (DiT).
- **Ưu điểm:** Sinh âm thanh stereo 44.1 kHz chất lượng cao; tích hợp cơ chế kiểm soát độ dài (Timing-conditioned); dữ liệu huấn luyện an toàn bản quyền [7].
- **Hạn chế:** Tiêu tốn vRAM lớn, giới hạn độ dài ở mức 47 giây cho một lần sinh.

3.3 LeVo (2025)

- **Ý tưởng chính:** Khung sinh bài hát chất lượng cao tập trung vào sự hòa hợp giữa giọng hát và nhạc đệm thông qua căn chỉnh đa sở thích [8].
- **Kiến trúc:** Sử dụng bộ giải mã tự hồi quy dự đoán song song các token rãnh kép kết hợp với kỹ thuật Direct Preference Optimization (DPO) [8].
- **Ưu điểm:** Giảm thiểu sự không khớp giữa nhạc cụ và giọng hát; chất lượng âm thanh cạnh tranh với các hệ thống công nghiệp đóng.
- **Hạn chế:** Phụ thuộc vào chất lượng tập dữ liệu đa rãnh trong quá trình huấn luyện.

3.4 ACE-Step (2025/2026)

- **Ý tưởng chính:** Mô hình nền tảng mã nguồn mở lai (hybrid) kết hợp tốc độ của khuếch tán với độ gắn kết của tự hồi quy [9].

- **Kiến trúc:** Kết hợp phương pháp sinh khuếch tán với Bộ mã hóa tự động nén sâu (DCAE) và kiến trúc Transformer tuyến tính nhẹ [9].
- **Ưu điểm:** Tốc độ suy luận cực nhanh (sinh 4 phút nhạc trong 20 giây trên GPU A100); độ gắn kết âm nhạc và lời bài hát cao.
- **Hạn chế:** Yêu cầu thiết lập môi trường phức tạp để tối ưu hóa inference.

3.5 AudioX (2026)

- **Ý tưởng chính:** Khung đa phương thức hợp nhất cho phép sinh âm thanh từ bất kỳ điều kiện đầu vào nào (Anything-to-Audio) như văn bản, video, hình ảnh [5].
- **Kiến trúc:** Dựa trên mạng lõi DiT kết hợp với module Đóng gói Thích ứng Đa phương thức (MAF) nhằm đồng bộ hóa chéo các phương thức đầu vào [5].
- **Ưu điểm:** Khả năng bám sát mệnh lệnh xuất sắc; tính linh hoạt cao trong việc lấy ngữ cảnh đa phương thức.

3.6 Stable Audio 3.0 (2026)

- **Ý tưởng chính:** Cải tiến mạnh mẽ khả năng sinh âm thanh định dạng dài và hỗ trợ thao tác chỉnh sửa sâu [6].
- **Kiến trúc:** Flow matching và Diffusion Transformer (DiT) kết hợp với bộ mã hóa tự động ngữ nghĩa-âm học [6].
- **Ưu điểm:** Sinh âm nhạc độ dài lên tới 6 phút; hỗ trợ các tác vụ inpainting (chỉnh sửa một hoặc nhiều đoạn), causal continuation; phiên bản Small và Medium là mã nguồn mở [6].

Bảng so sánh các mô hình chủ đạo:

Mô hình	Năm	Kiến trúc lõi	Cơ chế điều kiện	Ưu điểm nổi bật	Hạn chế
MusicGen	2023	Transformer Tự hồi quy	T5 / Giai điệu	Tốc độ suy luận tốt, dễ dàng tinh chỉnh (LoRA).	Giới hạn độ dài, thiếu cấu trúc dài hạn.

Stable Audio Open	2024	DiT	T5 / Thời gian	Âm thanh Stereo 44.1kHz, an toàn bản quyền.	Giới hạn độ dài (dưới 1 phút).
LeVo	2025	AR Decoder + DPO	Văn bản / Lời bài hát	Hòa âm giọng hát & nhạc cụ xuất sắc.	Độ phức tạp cao khi huấn luyện rãnh kếp.
ACE-Step	2026	DCAE + Linear Transformer	Văn bản / Ngữ nghĩa	Cực nhanh (4 phút/20s), liên kết lời nhạc vượt trội.	Đang trong giai đoạn tối ưu công cụ.
AudioX	2026	DiT + MAF module	Văn bản / Video / Ảnh	Sinh nhạc tám sát chỉ thị đa phương thức.	Tiêu tốn tài nguyên lớn cho đa phương thức.
Stable Audio 3.0	2026	DiT + Flow Matching	Văn bản / Thời gian	Nhạc dài 6+ phút, hỗ trợ inpainting, mã nguồn mở.	Phiên bản Large nhất vẫn đóng mã nguồn (API).

4. Prompt Engineering trong Text-to-Music Generation

4.1 Cấu trúc cơ bản của Prompt

Prompt âm nhạc yêu cầu cung cấp các điểm neo kỹ thuật rõ ràng. Một prompt tiêu chuẩn thường bao gồm: Thể loại, Nhịp độ, Khí nhạc (Instrumentation), Chỉ dẫn cấu trúc (Intro, Outro), và Sắc thái cảm xúc [10].

4.2 Kỹ thuật Tạo sinh Tăng cường Truy xuất (RAG)

Việc chuyển đổi ngôn ngữ thông thường sang ngôn ngữ chuyên ngành âm thanh gặp nhiều khó khăn. Phương pháp RAG hỗ trợ quá trình này bằng cách so sánh prompt của người dùng với các chú thích của chuyên gia (thông qua mô hình CLAP). Các thuật ngữ tương đồng được trích xuất và đưa vào LLM để viết lại thành một prompt cấp độ chuyên gia, giúp cải thiện chất lượng đầu ra mà không yêu cầu người dùng có kiến thức âm nhạc chuyên sâu [10].

5. Dataset cho Text-to-Music Generation

Dữ liệu là yếu tố cốt lõi quyết định chất lượng mô hình.

5.1 MusicCaps

- **Quy mô:** Khoảng 5.5 nghìn mẫu, độ dài 10 giây/mẫu [2].
- **Đặc điểm:** Dán nhãn thủ công bởi chuyên gia âm nhạc với danh sách thuộc tính và mô tả tự do [2].
- **Ứng dụng:** Chủ yếu dùng làm tập đánh giá (Benchmark) [11].
- **Hạn chế:** Chịu ảnh hưởng bởi tính chủ quan của người dán nhãn [11].

5.2 MTG-Jamendo

- **Quy mô:** Hơn 55,000 bản nhạc đầy đủ với 195 thẻ (tags) thuộc thể loại, nhạc cụ và cảm xúc [12].
- **Đặc điểm:** Dữ liệu mã nguồn mở theo giấy phép Creative Commons. Không có câu mô tả ngữ nghĩa dạng câu hoàn chỉnh [12].

5.3 IF-caps

- **Quy mô:** Khoảng 7 triệu mẫu [5].
- **Đặc điểm:** Dữ liệu được chú thích cấu trúc cho đa phương thức (video/văn bản/âm thanh) sử dụng để huấn luyện các khung mô hình hợp nhất như AudioX [5].

6. Đánh giá chất lượng Text-to-Music

Việc đánh giá phụ thuộc vào khung đánh giá kết hợp giữa chỉ số toán học và khảo sát con người.

6.1 Các chỉ số khách quan (Objective Metrics)

- **Fréchet Audio Distance (FAD):** Đo lường độ khác biệt phân phối giữa âm thanh AI sinh ra và tập tham chiếu. FAD ứng dụng các mô hình trích xuất như VGGish, PANNs, hoặc CLAP để phản ánh đánh giá nhận thức của con người [11].
- **Kernel Audio Distance (KAD):** Khắc phục sự phụ thuộc vào giả định phân phối chuẩn của FAD. KAD sử dụng Maximum Mean Discrepancy (MMD), hội tụ nhanh hơn với lượng mẫu nhỏ và cung cấp một thang đo hiệu quả, tin cậy hơn [13].
- **CLAP Score:** Tính toán độ tương đồng Cosin giữa văn bản và âm thanh sinh ra trong không gian nhúng của CLAP, đo lường độ bám sát mệnh lệnh (Prompt Adherence) [11].

6.2 Các chỉ số chủ quan (Subjective Metrics)

- **Mean Opinion Score (MOS):** Khảo sát chấm điểm trực tiếp từ 1-5 cho Chất lượng tổng thể [1].
- **Khảo sát so sánh cặp:** Người nghe chọn mẫu tốt hơn giữa hai lựa chọn, giúp giảm độ chệch tâm lý của phương pháp chấm điểm tuyệt đối [11].

7. Research gaps và Thách thức hiện tại

7.1 Khả năng điều khiển đa phương thức chi tiết:

Việc định tuyến chính xác từng mili-giây âm nhạc khớp với khung hình video vẫn chưa hoàn hảo, đòi hỏi thêm nghiên cứu về sự đồng bộ chéo [5].

7.2 Sự thiếu hụt dữ liệu văn hóa địa phương:

Các bộ dữ liệu khổng lồ vẫn chủ yếu mang âm hưởng phương Tây. Âm nhạc đa văn hóa hoặc nhạc cụ truyền thống của các quốc gia đang phát triển ít được đưa vào tập huấn luyện [11].

7.3 Chi phí tính toán và Kiến trúc:

Các mô hình tự hồi quy bị giới hạn bởi cửa sổ ngữ cảnh, trong khi quá trình giải nhiễu của mô hình khuếch tán tạo độ trễ lớn, đòi hỏi liên tục tối ưu hóa các kiến trúc lai [3].

8. Hướng triển khai đồ án

Dựa trên công nghệ năm 2026, việc huấn luyện mô hình sinh nhạc từ đầu là không khả thi do yêu cầu tài nguyên khổng lồ. Sử dụng phương pháp tinh chỉnh hiệu quả tham số (PEFT) kết hợp với các mô hình nền tảng mã nguồn mở là giải pháp tối ưu.

- **Tên đề tài:** "Tinh chỉnh mô hình Text-to-Music thế hệ mới ứng dụng trong sinh âm nhạc truyền thống Việt Nam sử dụng phương pháp PEFT/LoRA."
- **Lý do lựa chọn:**
 - *Tính mới:* Âm nhạc truyền thống Việt Nam (đàn bầu, nhịp phách, chèo, ca trù) là những khái niệm chưa tồn tại trong các mô hình của phương Tây.
 - *Tính khả thi:* Kỹ thuật Low-Rank Adaptation (LoRA) chỉ cập nhật các lớp chú ý (attention/projection layers) cốt lõi, giảm thiểu tài nguyên và cho phép huấn luyện với chi phí tính toán thấp [14].
- **Kiến trúc giải pháp:**
 1. **Dữ liệu:** Thu thập âm thanh nhạc cụ dân tộc. Sử dụng LLM hoặc kỹ thuật Pseudo-labeling để tự động sinh văn bản mô tả (captioning) bằng tiếng Anh.
 2. **Mô hình lõi:** Sử dụng Stable Audio 3.0 Small (hỗ trợ inpainting) [6] hoặc ACE-Step [9] làm mô hình nền tảng.
 3. **Tinh chỉnh (Fine-tuning):** Áp dụng kỹ thuật LoRA vào các lớp mạng để mô hình học các âm sắc nhạc cụ và nhịp điệu dân tộc mới [14].
 4. **Prompt Engineering:** Xây dựng một quy trình dịch và cấu trúc hóa prompt bằng LLM (RAG) [10].
 5. **Đánh giá:** Tính toán các chỉ số khách quan như KAD, FAD và CLAP Score để đánh giá chất lượng mô hình sau tinh chỉnh [11].

9. Tài liệu tham khảo

- [1] Dong, J. (2025), "A Survey of Text-to-Music Generation with Deep Learning", *Applied and Computational Engineering*.
- [2] Agostinelli, A., et al. (2023), "MusicLM: Generating Music From Text", *arXiv preprint arXiv:2301.11325*.
- [3] Copet, J., et al. (2023), "Simple and Controllable Music Generation", *Advances in Neural Information Processing Systems (NeurIPS)*.
- [4] Evans, Z., et al. (2024), "Stable Audio Open", *arXiv preprint arXiv:2407.14358*.
- [5] Lei, S., et al. (2025), "LeVo: High-Quality Song Generation with Multi-Preference Alignment", *arXiv preprint arXiv:2506.07520*.
- [6] Gong, J., et al. (2025), "ACE-Step: A Step Towards Music Generation Foundation Model".
- [7] Tian, Z., et al. (2026), "AudioX: A Unified Framework for Anything-to-Audio Generation", *International Conference on Learning Representations (ICLR 2026)*.
- [8] Stability AI (2026), *Stable Audio 3.0 Model Architecture & Release*, Báo cáo kỹ thuật.
- [9] Ding, M., et al. (2025), "Enhancing Text-to-Music Generation Through Retrieval-Augmented Prompt Rewrite".
- [10] Bogdanov, D., et al. (2019), "The MTG-Jamendo Dataset for Automatic Music Tagging", *Machine Learning for Music Discovery Workshop, ICML*.
- [11] Gui, A., et al. (2024), "Adapting Frechet Audio Distance for Generative Music Evaluation", *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*.
- [12] Chung, Y., et al. (2025), "KAD: No More FAD! An Effective and Efficient Evaluation Metric for Audio Generation", *arXiv preprint arXiv:2502.15602*.
- [13] Ding, M., et al. (2025), "Enhancing Text-to-Music Generation Through Retrieval-Augmented Prompt Rewrite".

[14] Liu, H., et al. (2023), "AudioLDM: Text-to-Audio Generation with Latent Diffusion Models", *International Conference on Machine Learning (ICML 2023)*.